

Clustering 성능 기준

1) 정량화한 값 (cluster의 갯수 및 소속)을 알고 있는 경우.

$X \backslash Y$	Y_1	Y_2	...	Y_s	Sums
X_1	n_{11}	n_{12}	...	n_{1s}	a_1
X_2	n_{21}	n_{22}	...	n_{2s}	a_2
\vdots	\vdots	\vdots		\vdots	\vdots
X_r	n_{r1}	n_{r2}	...	n_{rs}	a_r
Sums	b_1	b_2	...	b_s	

- Adjusted Rand Index

- 1) n_{ij} : X clustering에 cluster X_i 일 때, Y clustering에 cluster Y_j 일 때의 data 개수
- 2) a_i : X clustering에 cluster X_i 일 때, Y clustering에 cluster Y_j 일 때의 data 개수
- 3) b_j : X clustering에 cluster X_i 일 때, Y clustering에 cluster Y_j 일 때의 data 개수

$$\text{Adjusted Rand Index} = \frac{\sum_{i,j} (n_{ij}) - \left[\sum_i (a_i) \sum_j (b_j) \right] / \binom{n}{2}}{\frac{1}{2} \left[\sum_i (a_i) + \sum_j (b_j) \right] - \left[\sum_i (a_i) \sum_j (b_j) \right] / \binom{n}{2}}$$

Max Index Expected Index

- Adjusted Mutual Information

$$X = \{X_1, X_2, \dots, X_r\}$$

$$Y = \{Y_1, Y_2, \dots, Y_s\}$$

$$P(i) = \frac{|X_i|}{N}$$

$$P(i,j) = \frac{|X_i \cap Y_j|}{N}$$

$$MI(X,Y) = \sum_{i=1}^r \sum_{j=1}^s P(i,j) \log \frac{P(i,j)}{P(i)P(j)}$$